

Sentinela Agroclimática: Um Sistema de Monitoramento de Risco Agrícola Baseado em Fusão de Sensores Orbitais e Inteligência Artificial

Marco Aurélio de Oliveira Martins¹

¹Instituto Hardware Brasil – Avenida Alan Turing 776, 3º andar, Cidade Universitária, Campinas – SP – Brasil

mmaureliom@gmail.com

Abstract. *This paper presents the “Sentinela Agroclimática”, a solution developed for Capacity Building in Aerospace Technologies with the application of AI in the Aerospace Sector. The system addresses the challenge of monitoring soybean crop productivity in tropical regions characterized by high cloud cover, such as Mato Grosso. By fusing data from optical (Sentinel-2), radar (Sentinel-1), thermal (MODIS), and soil moisture (SMAP) sensors using the Google Earth Engine, the solution implements a Random Forest algorithm to dynamically weigh environmental variables based on historical productivity. The result is a robust Agronomic Water Stress Index (IEHA) that supports rural credit analysis with explainable metrics and resilience to weather interference.*

Resumo. *Este artigo apresenta o “Sentinela Agroclimática”, solução desenvolvida para a Capacitação em Tecnologias Aeroespaciais com aplicação de IA no Setor Aeroespacial. O sistema aborda o desafio de monitorar a produtividade da soja em regiões tropicais com alta cobertura de nuvens, como o Mato Grosso. Através da fusão de dados de sensores ópticos (Sentinel-2), radar (Sentinel-1), termais (MODIS) e de umidade do solo (SMAP) via Google Earth Engine, a solução implementa um algoritmo Random Forest para ponderar dinamicamente as variáveis ambientais com base no histórico de produtividade. O resultado é um Índice de Estresse Hídrico Agrônomo (IEHA) robusto que apoia a análise de crédito rural com métricas explicáveis e resiliência a interferências meteorológicas.*

1. Introdução

A agricultura de precisão e a análise de risco para concessão de crédito rural (crédito agrícola), dentre outras aplicações financeiras, enfrentam um desafio crítico em regiões tropicais: a incerteza climática e a dificuldade de monitoramento remoto durante a estação chuvosa. No Brasil, e especificamente no estado do Mato Grosso, maior produtor nacional de soja, o período de desenvolvimento da cultura coincide com meses de intensa cobertura de nuvens. Este cenário limita severamente a eficácia dos métodos tradicionais de sensoriamento remoto baseados puramente em índices ópticos, como o NDVI (*Normalized Difference Vegetation Index*), que dependem de condições atmosféricas claras.

Bancos e seguradoras necessitam de ferramentas que não apenas monitorem o vigor vegetativo, mas que quantifiquem o risco produtivo em tempo real, permitindo uma avaliação de crédito (*credit score*) mais justa e precisa. A ausência de dados

confiáveis durante janelas críticas da safra pode levar a uma precificação inadequada do risco ou à concessão de crédito para áreas com baixa aptidão produtiva momentânea.

Este trabalho descreve a implementação da plataforma “Sentinela Agroclimática”, que usa Inteligência Artificial no setor aeroespacial. O objetivo principal da solução é prover um painel de monitoramento contínuo do estresse hídrico e estimativa de produtividade da soja na região de Mato Grosso.

A inovação proposta reside em três pilares fundamentais: (1) Fusão Multissensor, integrando dados de radar (SAR) que penetram nuvens com dados ópticos e climáticos; (2) IA Adaptativa, utilizando o algoritmo *Random Forest* para aprender as especificidades locais de cada talhão, gerando pesos dinâmicos para o cálculo de risco; e (3) Resiliência Operacional, através de um mecanismo de *fallback* automático que garante a continuidade do monitoramento mesmo sob 100% de cobertura de nuvens.

2. Fundamentação Teórica e Dados

A solução foi construída sobre a infraestrutura do Google Earth Engine (GEE), permitindo o processamento de *Petabytes* de dados geoespaciais em nuvem. A seleção dos sensores orbitais foi estratégica para cobrir todas as dimensões do desenvolvimento da planta.

2.1. Constelação de Satélites Utilizada

O sistema ingere e processa cinco fontes de dados distintas:

1. Sentinel-2 (Óptico - ESA): Utilizado para calcular o NDVI e o NDMI (*Normalized Difference Moisture Index*). Oferece alta resolução espacial (10 m) para avaliar o vigor e o conteúdo de água nas folhas, mas é vulnerável a nuvens.

2. Sentinel-1 (Radar SAR - ESA): Peça-chave para a resiliência do sistema. Opera na banda C e captura a retroespalhamento (*backscatter*) nas polarizações VV e VH. A banda VH, em particular, correlaciona-se fortemente com a biomassa e estrutura volumétrica da cultura, funcionando dia e noite, independente de chuva ou nuvens.

3. MODIS (Termal - NASA): O sensor MODIS (produto MOD11A2) fornece a Temperatura da Superfície Terrestre (LST - *Land Surface Temperature*). O estresse térmico é um precursor do estresse hídrico visível.

4. CHIRPS (Precipitação): Dados de precipitação diária que combinam estações meteorológicas com infravermelho de satélite, essenciais para o balanço hídrico.

5. SMAP (Umidade do Solo - NASA): O satélite *Soil Moisture Active Passive* fornece a umidade superficial do solo (SSM), completando o ciclo hidrológico monitorado.

2.2. Aprendizado de Máquina na Agricultura

A aplicação de IA no setor aeroespacial agrícola muitas vezes foca apenas na classificação de uso do solo. Neste projeto, avançamos para a regressão e interpretabilidade. Utilizamos o *Random Forest Regressor*, um método de aprendizado *ensemble* robusto a *overfitting* e capaz de lidar com a não-linearidade das relações entre clima e produtividade. O diferencial da abordagem é o uso da IA não apenas para prever a produtividade final, mas para extrair a importância das variáveis (*feature importance*), permitindo que o sistema “entenda” quais fatores limitantes são mais críticos para cada região analisada.

Exemplo:

- Sinal negativo: NDVI, NDMI, Chuva, Umidade do Solo, VV, VH.
- Sinal positivo: LST.

O peso final é computado como:

$$peso_f = importancia_f \times sinal_f$$

Isso garante coerência agrônômica: valores altos de LST elevam o estresse; quedas em NDVI/NDMI/chuva também.

2.3. Diagnóstico Explicável: Momentum e Direção do Estresse

A detecção de “Piora Recente” ou “Melhora Recente” é um mecanismo essencial de interpretabilidade. Para cada variável, calcula-se a média móvel de 3 períodos do Z-Score e a sua derivada (tendência temporal). O sistema define um limiar de sensibilidade de tendência de ± 0.05 .

A lógica booleana para o diagnóstico:

- Piora Recente (agravando)

Ocorre se a causa principal atende a uma das condições:

1. Possui peso negativo (ex: chuva) E a tendência é inferior a -0.05 .
2. Possui peso positivo (ex: LST) E a tendência é superior a $+0.05$.

- Melhora Recente

Ocorre se a causa principal atende a uma das condições:

1. Possui peso negativo E a tendência é superior a $+0.05$.
2. Possui peso positivo E a tendência é inferior a -0.05 .

Essa lógica combina estatística e agronomia para explicar o motivo físico do risco, permitindo ao analista distinguir entre uma flutuação natural e uma tendência de degradação.

2.4. Fallback Multissensor

Quando a confiança óptica do Sentinel-2 cai abaixo de 0.3, o sistema ativa automaticamente o modo de contingência:

1. Os pesos das variáveis ópticas (NDVI e NDMI) são forçados a zero.
2. A responsabilidade pelo monitoramento é transferida para os sensores de Radar (Sentinel-1 VV/VH) e Umidade do Solo (SMAP).
3. O status exibe a anotação explícita: “*Radar/SMAP*”.

Esse recurso garante resiliência operacional e continuidade do monitoramento mesmo sob 100% de nebulosidade.

2.5. Projeção Futura e Correção de Viés

O sistema treina um segundo modelo *Random Forest* especializado para aprender a sazonalidade do IEHA. Este modelo utiliza exclusivamente o dia do ano como variável preditora para capturar o comportamento cíclico intra-anual. A curva projetada recebe

uma correção de viés baseada na diferença entre o valor real atual e a predição do modelo para hoje:

$$\delta = IEHA_{atual} - IEH\hat{A}_{modelo}(t_{atual})$$

Os alertas futuros são determinados pela inclinação da regressão linear sobre a projeção:

- Risco Agravado: Inclinação $> +0.05$.
- Tendência de Melhora: Inclinação < -0.05 .

3. Metodologia e Implementação

A arquitetura do sistema foi desenvolvida em Python, integrando uma pilha tecnológica robusta para processamento científico e visualização geoespacial. A manipulação de séries temporais utiliza as bibliotecas Pandas e NumPy, enquanto a modelagem preditiva é executada via Scikit-learn. A interface de usuário foi construída sobre o *framework* Streamlit, utilizando geemap para renderização cartográfica e Plotly Express para visualizações analíticas interativas. O sistema inicia sua análise centralizado nas coordenadas de referência do polo estratégico de Sorriso-MT (-12.2340821, -55.7533832).

Para garantir a replicabilidade e a estabilidade da conexão com o Google Earth Engine (GEE), a autenticação utiliza explicitamente o identificador do projeto GCP “projetoaero”. Visando a otimização de performance e a redução de latência, as funções críticas de coleta de dados (`coletar_dados_gee`) e de busca de metadados (`buscar_dados_imagens`) implementam um mecanismo de *caching* com TTL (*Time-To-Live*) de 3600 segundos (1 hora), evitando requisições redundantes à API.

3.1. Parâmetros de Configuração e Constantes

A parametrização do sistema adota valores *default* calibrados para a região de estudo, permitindo alguns ajustes via interface. As configurações padrão críticas para a inicialização do sistema são:

1. Escala de Agregação: A resolução espacial padrão utilizada para a extração estatística de pixels no GEE é definida em 100 metros (`escala_m`).
2. Passo Temporal: A análise opera com um intervalo padrão de 15 dias (`passo_dias`), configurável via *sidebar*.
3. Limiares de Risco: O limiar padrão de “Alerta” na escala IEHA (0 a 10) é definido em 7.5 e ajustável pelo usuário. O limiar de “Atenção” é definido como 80% desse valor (coeficiente 0.8).

3.2. Pipeline de Processamento (ETL)

O fluxo de dados implementado envolve tratamento específico para garantir a integridade estatística das séries temporais.

3.2.1 Pré-processamento Geoespacial

Para assegurar a qualidade do sinal físico e a consistência visual, aplicam-se filtros e métodos de agregação específicos no servidor do GEE:

1. Filtragem de Radar (Sentinel-1): A coleção é filtrada para o modo de aquisição “IW” (*Interferometric Wide Swath*) para garantir cobertura ampla. Para

mitigar o ruído inerente (*speckle*), aplica-se um filtro de média móvel (*focal_mean*) com raio de 50 metros nas polarizações VV e VH.

2. Máscara de Nuvens (Sentinel-2): A filtragem de pixels contaminados utiliza a banda QA60, mascarando bit-a-bit os valores 10 (nuvens opacas) e 11 (cirrus).

3. Normalização Óptica e Visualização: Os valores digitais brutos (DN) são divididos pelo fator escalar 10.000 para conversão em reflectância (0-1).

4. Agregação de Precipitação (CHIRPS): A precipitação é calculada como a média diária em mm/dia (*chirps_fil.mean()*), normalizando os dados para comparação independente da duração exata dos intervalos.

5. Termometria (MODIS): A conversão da temperatura bruta (DN) para Celsius segue a equação do produto MOD11A2: $LST_{oC} = (DN \times 0.02) - 273.15$.

3.2.2 Tratamento Temporal e Imputação

O sistema implementa uma regra de Ano Agrícola onde observações a partir de julho iniciam uma nova safra. Na definição do *baseline*, safras cuja produtividade (valores extraídos da tabela 5457 do Sistema IBGE de Recuperação Automática (SIDRA)) diverge mais de 15% da mediana histórica são removidas como *outliers*.

Para garantir a continuidade das séries temporais, aplica-se uma estratégia de imputação sequencial restrita exclusivamente às colunas numéricas do DataFrame (*df.select_dtypes(include=np.number)*):

1. Interpolação Linear: Aplicação de *interpolate(method='linear')* para conectar pontos distantes.

2. Preenchimento Frontal: Uso de *ffill()* para propagar o último valor válido.

3. Preenchimento Traseiro: Uso de *bfill()* para resolver lacunas no início da série.

3.3. Cálculo do IEHA e Diagnóstico

O Índice de Estresse Hídrico Agrônômico (IEHA) é derivado de um Z-Score médio ponderado, transformado para uma escala de 0 a 10 através da função $IEHA = 5 + (Z_{médio} \times 2.5)$.

3.3.1 Causa Principal Determinística

Para garantir a explicabilidade, o sistema identifica a Causa Principal do estresse de forma determinística. A variável eleita é aquela que apresenta a maior contribuição absoluta para a soma do índice naquele instante temporal:

$$Causa = \underset{var}{argmax} (|Z_{var} \times W_{var}|)$$

A taxonomia da mensagem de status segue a estrutura:

$$Status = [NIVEL] + [CAUSA] + [MOMENTUM] + [FALLBACK]$$

4. Resultados

O protótipo foi validado em uma região de referência em Sorriso-MT.

4.1. Previsão de Produtividade

A estimativa de produtividade da safra corrente não é uma extrapolação linear, mas sim o resultado da inferência do modelo *Random Forest* treinado. O sistema calcula a média acumulada das variáveis ambientais da safra atual até a data mais recente e submete este vetor médio ao modelo, retornando a predição em kg/ha. A variação em relação à média é quantificada pelo Delta Percentual:

$$\% \Delta = \frac{Previsão_{atual} - Média Histórica}{Média Histórica} \times 100$$

4.2. Análise de Importância de Variáveis

O gráfico de importância de variáveis revelou que, para a região de estudo, as bandas VH do radar Sentinel-1 e a temperatura da superfície (LST) tiveram correlação mais alta com a quebra de safra do que o NDVI isolado, validando a hipótese de que sensores que superam nuvens são cruciais em regiões tropicais.

4.3. Visualização Geoespacial

O módulo de inspeção visual implementa filtros na interface de usuário, excluindo automaticamente imagens disponíveis com cobertura de nuvens (CLOUDY_PIXEL_PERCENTAGE) superior a 60%. As visualizações de inspeção (*Drill-Down*) utilizam as seguintes composições espectrais e limites de contraste exatos:

- RGB Real: Bandas B4, B3, B2 (intervalo 0 a 0.3).
- NDVI: Normalização entre B8 e B4 (intervalo 0 a 0.8).
- Estresse (NDWI): Normalização entre B8 e B11 (intervalo -0.5 a 0.5).

Além disso, o contorno do talhão é renderizado em vermelho sobre a imagem, e o sistema aplica um *buffer* de segurança de 500 metros ao redor do polígono para o recorte visual final.

5. Discussão e Análise dos Resultados

A abordagem híbrida mostrou-se superior a abordagens estocásticas, garantindo continuidade de dados através do radar SAR e precisão diagnóstica através da IA explicável.

5.1. Resiliência Climática e Aplicabilidade

O Sentinela Agroclimática manteve o fluxo de informação ativo mesmo em períodos de predominância de chuvas. Para o crédito rural, a métrica unificada simplifica a decisão, enquanto a análise de momentum permite antecipação de riscos.

5.2. Capturas de Tela da Solução Desenvolvida

Podemos observar abaixo a solução Sentinela Agroclimática após a realização da análise de uma região de interesse, um talhão de cultura de soja na região de Sorriso-MT. Após a seleção da região de interesse, a solução exibe as primeiras informações resumidas sobre o momento, se alerta ou normalidade, exibe mais abaixo o IEHA

histórico, a previsão de produtividade e tendência IEHA, a opção de inspeção visual da região de interesse em determinadas datas e, por fim, a explicação de como os dados foram processados nessa análise.



Figura 1. Captura de tela da solução com a definição de talhão e primeiros resultados da análise.




Figura 2. Captura de tela da solução com o IEHA histórico.




Figura 3. Captura de tela da solução com a previsão de produtividade e tendência IEHA.




Figura 4. Captura de tela da solução com a inspeção visual do estresse (NDWI) da região de interesse no dia 27/05/2025.




Figura 5. Captura de tela da solução com a explicação de como as variáveis impactaram no processamento.

▼ Dados Brutos do Baseline Sazonal (O "Normal" de cada Quinzena)

Estas são as médias e desvios padrão históricos usados para calcular o Z-Score.

	NDVI		NDMI		LST		precip_mm_day		ssm		VV		VH	
quinzena	mean	std	mean	std	mean	std	mean	std	mean	std	mean	std	mean	std
0	0.4287	0.2803	0.1931	0.172	34.36	4.371	7.1625	2.3383	0.3056	0.0212	-8.5513	1.1209	-14.417	1.0571
1	0.2736	0.158	-0.1773	0.1487	38.1628	3.1186	11.5868	4.857	0.3284	0.0256	-9.2998	1.688	-16.4398	3.1685
2	0.2601	0.2582	0.1246	0.2119	36.8633	3.2502	14.3076	2.7855	0.327	0.0139	-8.6612	0.9433	-15.561	1.8775
3	0.4165	0.2322	0.2455	0.1935	29.7281	2.062	15.8696	3.0829	0.323	0.0184	-8.0805	0.8852	-14.9302	0.5318
4	0.5704	0.1881	0.3194	0.0902	29.06	2.3173	18.4492	4.0715	0.2799	0.0128	-8.325	0.6762	-14.7482	0.6185
5	0.5187	0.2664	0.3135	0.0654	29.148	1.4677	10.5347	7.1342	0.2611	0.0324	-8.3582	0.2892	-14.7446	0.3071
6	0.6308	0.2178	0.3146	0.0394	27.4413	0.7685	3.8686	2.2699	0.2449	0.027	-8.0422	0.3476	-14.6828	0.3058
7	0.6961	0.1162	0.2161	0.1827	28.7687	1.4131	2.1339	1.7727	0.2124	0.0253	-9.0138	0.8711	-16.0891	1.0258
8	0.5158	0.183	0.0429	0.1955	30.0637	1.5486	0.4222	0.2452	0.1878	0.014	-10.3885	1.8311	-17.6229	1.7416

▼ Tabela Final Processada

	LST	VH	VV	confianca_s2	date	precip_mm_day	ssm	NDMI	NDVI	safr	quinzena	NDVI_z	NDVI_trend	NDMI_z	NDMI_trend	LST_z	LST_trend	precip_mm_day_z	precip_mm_day_trend
0	39.491	-15.9636	-8.7113	0	2018-10-01 00:00:00	5.2834	0.2613	0.3533	0.8187	2018/2019	18	1.7639	0	1.5833	0	-0.9111	0	-1.1863	0
1	37.2616	-17.9641	-9.8879	0	2018-10-16 00:00:00	10.4873	0.315	0.3533	0.8187	2018/2019	19	1.7	-0.0319	1.6224	0.0195	-0.6333	0.1389	1.0689	1.1276
2	29.1997	-15.4266	-7.7847	0	2018-10-31 00:00:00	7.0236	0.289	0.3533	0.8187	2018/2019	20	1.0918	-0.2134	0.757	-0.2819	-1.4643	-0.2307	-0.3766	-0.106
3	29.0322	-15.2603	-8.0696	0	2018-11-15 00:00:00	9.2955	0.2911	0.3533	0.8187	2018/2019	21	1.0402	-0.2412	1.294	-0.0964	-0.1618	0.2498	0.0958	0.4274
4	28.5152	-15.7376	-8.0012	1	2018-11-30 00:00:00	14.6347	0.3071	0.3533	0.8187	2018/2019	22	0.4856	-0.4048	1.1238	-0.1662	0.2689	0.3008	0.3837	-0.2284
5	28.3785	-14.9704	-8.3887	1	2018-12-15 00:00:00	6.7922	0.3005	0.312	0.7532	2018/2019	23	0.4081	-0.2279	-1.189	-0.6487	0.404	0.6228	-1.1804	-0.2679
6	32.6614	-13.0318	-6.9999	1	2018-12-30 00:00:00	8.8526	0.3312	0.2707	0.6878	2018/2019	24	0.7071	-0.111	0.7071	-0.1956	0.7071	0.2896	-0.7071	-0.2877
7	38.02	-15.9042	-9.6645	1	2019-01-14 00:00:00	10.2059	0.3243	-0.0098	0.4584	2018/2019	0	0.1058	-0.1266	-1.1796	-0.7678	0.8374	0.1895	1.3015	0.3059
8	43.3786	-21.5144	-12.0515	1	2019-01-29 00:00:00	11.2518	0.3359	-0.2904	0.229	2018/2019	1	-0.2823	-0.2301	-0.7602	0.1429	1.6725	0.4228	-0.069	0.3705

Figura 6. Captura de tela da solução com a exibição dos dados brutos e tabela final processada.

6. Conclusão

O projeto cumpre o objetivo de aplicar IA no setor aeroespacial, superando limitações climáticas via fusão de sensores. A explicitação dos parâmetros de pré-processamento, como o filtro de *speckle* de 50 m no radar e a calibração térmica precisa, garante a replicabilidade científica da solução.

Para o crédito rural, a métrica unificada simplifica a decisão, enquanto a análise de *momentum* permite a antecipação de riscos. O sistema oferece um futuro mais seguro e justo para a avaliação de crédito no setor agrícola, especialmente em regiões desafiadoras.

7. Referências

- Drusch, M., et al. (2012). Sentinel-2: ESA's Optical High-Resolution Mission for GMES Operational Services. "Remote Sensing of Environment", 120, 25-36.
- Gorelick, N., et al. (2017). Google Earth Engine: Planetary-scale geospatial analysis for everyone. "Remote Sensing of Environment", 202, 18-27.
- Torres, R., et al. (2012). GMES Sentinel-1 mission. "Remote Sensing of Environment", 120, 9-24.
- Wan, Z. (2014). New refinements and validation of the collection-6 MODIS land-surface temperature/emissivity product. "Remote Sensing of Environment", 140, 36-45.